

Auto-évaluation

Construisez et testez une infrastructure de données



Un dernier doute avant l'envoi de vos livrables ?

Pour vérifier la qualité de votre travail :

- cochez les cases ci-dessous : elles indiquent que vous avez bien pris en compte chaque indicateur de réussite ;
- renseignez, si besoin, la colonne "Notes" avec des commentaires sur vos livrables. Ils seront des points de discussion avec votre mentor pendant votre session de soutenance.

Quand toutes les cases de ce document seront cochées, vous pourrez déposer vos livrables sur la plateforme.

Bonne réussite !

Compétences	Livrables	Indicateurs de réussite de l'activité	Notes
Structurer l'architecture des données et concevoir des BDD	Schéma de la base de données	☐ J'ai conçu un schéma relationnel permettant de stocker les données issues de plusieurs sources météorologiques. ☐ J'ai unifié les données provenant de différentes sources dans un modèle de données cohérent. ☐ J'ai mis en place une modélisation analytique adaptée aux usages des Data Scientists (tables de faits et de dimensions). ☐ J'ai défini des relations claires entre les tables afin de garantir la cohérence des données.	
Définir et formaliser les processus de traitement et de stockage des données	Logigramme du processus suivi	☐ J'ai formalisé mon processus d'ingestion, de transformation, de test et de stockage des données sous la forme d'un logigramme utilisant des symboles standards. ☐ Mon logigramme décrit clairement une approche ELT (ingestion avec Airbyte, transformation avec DBT). ☐ Mon logigramme est lisible, clair et sans ambiguïté. ☐ J'ai représenté les principales étapes du pipeline ainsi que les cas d'erreur ou de contrôle.	

Modéliser une infrastructure compatible avec le SI	Architecture de la base de données	☐ J'ai représenté l'architecture physique de la plateforme de données. ☐ Mon architecture respecte les contraintes de la DSI (utilisation de Docker, de services AWS, d'Airbyte et de DBT). ☐ J'ai intégré PostgreSQL comme base de données centrale. ☐ J'ai pris en compte les mécanismes de haute disponibilité ou de réplication.	
Installer et paramétrer un système de gestion de base de données et un outil d'extraction	Installation fonctionnelle d'Airbyte	☐ J'ai utilisé Airbyte pour créer des flux d'ingestion des données depuis les différentes sources vers PostgreSQL. ☐ Les connecteurs d'extraction et de destination sont correctement configurés et fonctionnels. ☐ J'ai vérifié que les données sont chargées automatiquement dans PostgreSQL. ☐ J'ai pris une ou plusieurs captures d'écran des connecteurs Airbyte pour démontrer leur bon fonctionnement.	
Établir et exécuter un processus de test du SGBD	Reporting sur la qualité des données	☐ J'ai mis en place des tests automatisés avec DBT pour vérifier la qualité et l'intégrité des données. ☐ Je suis capable de justifier mes tests par rapport aux exigences du projet.	

		☐ J'ai utilisé des tests standards (unicité, valeurs non nulles, relations) et, si nécessaire, des règles métier. ☐ J'ai analysé et présenté les résultats des tests exécutés. ☐ J'ai mesuré et expliqué le temps d'accessibilité aux données après ingestion et transformation. ☐ J'ai documenté la méthodologie de test et les résultats obtenus.	
Installer et tester l'infrastructure de gestion des données	Installation testée et fonctionnelle	☐ J'ai conteneurisé Airbyte et DBT avec Docker et ai vérifié leur bon fonctionnement avant le déploiement sur AWS. ☐ J'ai déployé la base PostgreSQL sur AWS (Amazon RDS). ☐ J'ai automatisé l'exécution des transformations DBT sur AWS. ☐ J'ai configuré un système de monitoring pour surveiller les performances et l'état de l'infrastructure (ex. CloudWatch). ☐ Les logs d'activité sont correctement configurés et consultables. ☐ J'ai pris une ou plusieurs captures d'écran pour démontrer le bon fonctionnement de l'infrastructure dont un screenshot de la doc DBT avec le graphe lineage des modèles. ☐ Je suis capable d'effectuer une démonstration attestant que mon installation est fonctionnelle.	